第一章 强化学习

> 序贯决策（sequential decision making）：

在一系列**连续的时间点**上，根据当前的状态和已有的信息，**依次做出决策**的过程。它强调决策的顺序性和动态性，每一个决策的做出都可能会影响到后续的状态和可选择的决策路径，决策者需要综合考虑当前决策的即时效果以及对未来可能产生的长远影响，从而在多个时间步长上规划出**最优的决策序列**。

> 强化学习（reinforcement learning）

强化学习是机器通过与环境交互来实现目标的一种计算方法。

一种**试错型学习**（trial-and-error learning）范式。

智能体有3种关键要素，即感知、决策和奖励。

- 感知。智能体在某种程度上感知环境的状态，从而知道自己所处的现状。例如，下围棋的智能体感知当前的棋盘情况；无人车感知周围道路的车辆、行人和红绿灯等情况；机器狗通过摄像头感知面前的图像，通过脚底的力学传感器来感知地面的摩擦功率和倾斜度等情况。
- 决策。智能体根据当前的状态计算出达到目标需要采取的动作的过程。例如，针对当前的棋盘决定下一颗落子的位置；针对当前的路况，无人车计算出方向盘的角度和刹车、油门的力度；针对当前收集到的视觉和力觉信号，机器狗给出4条腿的齿轮的角速度。策略是智能体最终体现出的智能形式，是不同智能体之间的核心区别。
- 奖励。环境根据状态和智能体采取的动作，产生一个标量信号作为奖励反馈。这个标量信号衡量智能体这一轮动作的好坏。例如，围棋博弈是否胜利；无人车是否安全、平稳且快速地行驶；机器狗是否在前进而没有摔倒。最大化累积奖励期望是智能体提升策略的目标，也是衡量智能体策略好坏的关键指标。

> 有监督学习（supervised learning）

一种机器学习方法，它基于**带有标签的训练数据**来训练模型。在有监督学习中，每个训练样本都包含输入特征和对应的输出标签，模型通过学习这些输入与输出之间的映射关系来构建一个**预测函数**。例如，在图像识别任务中，训练数据可能包含许多标记为“猫”或“狗”的图片，模型会学习从图片的像素特征中识别出哪些特征与“猫”相关，哪些与“狗”相关，从而在给定新的图片时能够准确地预测出它是“猫”还是“狗”。

与强化学习的区别

有监督学习的任务建立在从给定的数据分布中采样得到的训练数据集上，通过优化在训练数据集中设定的目标函数（如最小化预测误差）来找到模型的最优参数。这里，训练数据集背后的数据分布是完全不变的。

在强化学习中，数据是在智能体与环境交互的过程中得到的。如果智能体不采取某个决策动作，那么该动作对应的数据就永远无法被观测到，所以当前智能体的训练数据来自之前智能体的决策结果。

> 占用度量（occupancy measure）

归一化的占用度量用于衡量在一个智能体决策与一个动态环境的交互过程中，采样到一个具体的状态动作对（state-action pair）的概率分布。

（智能体在环境中完成不同动作的频率记录）

强化学习本质的思维方式

- 强化学习的策略在训练中会不断更新，其对应的数据分布（即占用度量）也会相应地改变。因此，强化学习的一大难点就在于，智能体看到的数据分布是随着智能体的学习而不断发生改变的。
- 由于奖励建立在状态动作对之上，一个策略对应的价值其实就是一个占用度量下对应的奖励的期望，因此寻找最优策略对应着寻找最优占用度量。

> 强化学习的独特性

对于一般的有监督学习任务，我们的目标是找到一个**最优的模型函数**，使其在训练数据集上最小化一个给定的损失函数。在训练数据独立同分布的假设下，这个优化目标表示最小化模型在整个数据分布上的泛化误差（generalization error），用简要的公式可以概括为：

$$\text{最优模型} = \arg\min_{\text{模型}} \mathbb{E}_{(\text{特征，标签})\sim\text{数据分布}}[\text{损失函数}(\text{标签，模型}(\text{特征}))]$$

相比之下，强化学习任务的最终优化目标是最大化智能体策略在和动态环境交互过程中的价值。根据上诉分析，策略的价值可以等价转换成奖励函数在策略的占用度量上的期望，即：

$$\text{最优策略} = \arg\max_{\text{策略}} \mathbb{E}_{(\text{状态，动作})\sim\text{策略的占用度量}}[\text{奖励函数}(\text{状态，动作})]$$

两者的相似点和不同点

- 有监督学习和强化学习的**优化目标相似**，即都是在优化某个数据分布下的一个分数值的期望。
- 二者**优化的途径是不同的**，有监督学习直接通过**优化模型**对于数据特征的输出来优化目标，即修改目标函数而数据分布不变；强化学习则通过**改变策略来调整智能体和环境交互数据的分布**，进而优化目标，即修改数据分布而目标函数不变。
- 综上所述，一般有监督学习和强化学习的范式之间的区别为：
    - 一般的有监督学习关注寻找一个模型，使其在给定数据分布下得到的损失函数的期望最小；
    - 强化学习关注寻找一个智能体策略，使其在与动态环境交互的过程中产生最优的数据分布，即最大化该分布下一个给定奖励函数的期望。